

# Intelligent Online Notification Manager Using Machine Learning for the Standardization of Messaging Services in the Private Banking Sector

**Wilmer Andres Quispe Gomez**  
Faculty of Engineering  
Universidad Peruana de Ciencias Aplicadas (UPC)  
Lima, Peru  
u202324341@upc.edu.pe

**Moises Jhonatan Lagos Pachas**  
Faculty of Engineering  
Universidad Peruana de Ciencias Aplicadas (UPC)  
Lima, Peru  
u20171a978@upc.edu.pe

**Abstract** — Este artículo presenta el diseño de un gestor inteligente de notificaciones en línea que utiliza *machine learning* (ML) para unificar y optimizar la entrega de notificaciones digitales a través de múltiples servicios de comunicación en el sector de banca privada. El sistema propone una arquitectura basada en microservicios, integrada con una interfaz de programación de aplicaciones (API) escalable para homogeneizar canales como correo electrónico, SMS, notificaciones *push* y WhatsApp. Mediante la aplicación de modelos de aprendizaje por refuerzo y clasificación supervisada, el sistema determina el canal, el momento y el contenido de mensaje óptimos para cada usuario. La implementación asegura el cumplimiento de la normativa regulatoria peruana (Ley N. 29733, Resolución SBS N. 504-2021) y de estándares internacionales de seguridad (ISO/IEC 27001). Este trabajo contribuye a la modernización de los sistemas de comunicación en las instituciones financieras al mejorar la experiencia del cliente, la eficiencia operativa y la trazabilidad.

**Keywords** - *machine learning; mensajería multicanal; API; tecnología financiera; sistema de notificaciones*

## I. INTRODUCCIÓN

En la actual era digital, las instituciones financieras enfrentan una presión creciente para ofrecer experiencias de comunicación consistentes, seguras y personalizadas a sus clientes a través de múltiples canales. En el sector de banca privada, este desafío se intensifica por la coexistencia de servicios de notificación heterogéneos, como Firebase, APNs, correo electrónico y SMS, que suelen operar de forma aislada y generan fragmentación, esfuerzos duplicados y mayores costos operativos [1]. Este artículo aborda dicho problema mediante la propuesta de un gestor inteligente de notificaciones en línea, impulsado por *machine learning*, para unificar y optimizar la entrega de mensajes a través de una API escalable y segura.

El problema resultó relevante porque los sistemas de notificación constituyen una interfaz crítica entre los bancos y sus clientes. De acuerdo con Twilio [2], el 98% de los clientes espera experiencias de comunicación consistentes en todos los

canales. Sin embargo, plataformas existentes como OneSignal, Airship o Amazon SNS carecen de inteligencia adaptativa capaz de aprender el comportamiento del usuario, predecir los momentos óptimos de envío o seleccionar dinámicamente el canal más efectivo. Estas limitaciones han impedido que las instituciones financieras alcancen una verdadera consistencia omnicanal y una eficiencia operativa sostenida.

El problema también resultó complejo porque los enfoques ingenuos de mensajería multicanal suelen basarse en reglas estáticas y configuraciones manuales que no se adaptan al contexto ni a los patrones de respuesta del usuario. Además, el entorno bancario impone restricciones adicionales —como el estricto cumplimiento regulatorio (por ejemplo, la Resolución SBS N. 504-2021) y la confidencialidad de los datos— que vuelven la integración y la automatización aún más desafiantes.

Las soluciones previas se han centrado principalmente en la integración técnica, dejando de lado la toma de decisiones inteligente. Si bien algunos marcos como el *Integrated Multi-channel Messaging Model* (IM3) [3] proporcionan una base estructural para la transformación y el enrutamiento de mensajes, no incorporan algoritmos de aprendizaje que optimicen el flujo de comunicación. Otros estudios han demostrado que la aplicación de *machine learning* en notificaciones puede mejorar de manera significativa el compromiso y las tasas de respuesta [4], pero estas propuestas no se han adaptado a los requisitos específicos del sector financiero.

La contribución de este trabajo consistió en desarrollar y plantear la validación de un modelo inteligente de gestión de notificaciones que combina aprendizaje por refuerzo y análisis predictivo para determinar el canal, el momento y el contenido óptimos de cada mensaje. El sistema propuesto buscó (1) unificar los servicios de comunicación existentes mediante una arquitectura basada en APIs, (2) optimizar la entrega de mensajes a través de aprendizaje adaptativo y (3) asegurar el cumplimiento regulatorio y la seguridad exigidos por la industria financiera. Aunque el prototipo inicial se enfocó en un caso de estudio del BBVA en el Perú, el modelo conceptual resultó extensible a otras instituciones financieras que enfrentan desafíos similares de interoperabilidad y personalización.

El artículo se estructuró de la siguiente manera: la Sección II presentó el marco teórico y los trabajos relacionados; la Sección III describió el marco metodológico y las fuentes de datos; la Sección IV introdujo el modelo y la arquitectura propuestos; la Sección V discutió la propuesta de validación del sistema; y la Sección VI presentó las conclusiones y las líneas de trabajo futuro.

## II. TRABAJOS RELACIONADOS – ESTADO DEL ARTE

Para el desarrollo de esta investigación se realizó una *revisión sistemática de la literatura* sobre sistemas de notificaciones inteligentes, arquitecturas de mensajería multicanal y aplicación de técnicas de *machine learning* en el contexto de la banca y de servicios digitales. Con el fin de orientar la búsqueda y el análisis de los trabajos se plantearon las siguientes preguntas de investigación:

- **Q1:** ¿Qué arquitecturas y *frameworks* de mensajería multicanal se utilizan para gestionar notificaciones en entornos distribuidos, particularmente en organizaciones de servicios y entidades financieras?
- **Q2:** ¿Qué técnicas o algoritmos de *machine learning* se emplean para optimizar el envío, el canal y el contenido de notificaciones a usuarios finales?
- **Q3:** ¿Qué propuestas tecnológicas existen para implementar sistemas de gestión inteligente de notificaciones u orquestadores omnicanal en banca u otros sectores afines?
- **Q4:** ¿Cómo se validan y evalúan los sistemas de notificaciones inteligentes en términos de precisión del modelo, experiencia de usuario y métricas operativas (entrega, apertura, latencia, entre otros)?

Estas preguntas garantizan que los estudios seleccionados aborden los componentes esenciales de la presente propuesta: *arquitectura multicanal*, inteligencia basada en *machine learning*, modelo de orquestación de notificaciones y mecanismos de validación.

### A. Metodología de búsqueda y selección

Siguiendo una metodología de revisión sistemática, se realizó una búsqueda en bancos de revistas y bases de datos académicas confiables tales como *IEEE Xplore*, *ACM Digital Library*, *ScienceDirect*, *SpringerLink*, *Scopus* y *MDPI*, entre otras. Se emplearon combinaciones de palabras clave en inglés, tales como:

- “*multi-channel notification system*”, “*notification orchestration*”,
- “*machine learning for notifications*”, “*push notification optimization*”,
- “*banking communication channels*”, “*context-aware notifications*”,
- “*reinforcement learning notifications*”, “*multi-channel messaging framework*”.

Como criterios de inclusión, se consideraron:

- Artículos científicos revisados por pares.
- Publicaciones entre 2020 y 2024, con algunos trabajos base previos cuando aportaban fundamentos teóricos relevantes.

- Estudios que respondan al menos a una de las preguntas Q1–Q4.
- Trabajos que aborden explícitamente notificaciones, mensajería multicanal, personalización u optimización de la comunicación con usuarios.

Como criterios de exclusión, se descartaron:

- Documentos puramente divulgativos o sin metodología claramente descrita.
- Trabajos centrados en sectores no extrapolables al contexto de servicios digitales o financieros.
- Propuestas que no utilicen técnicas de *machine learning* ni aporten elementos de orquestación multicanal.

Tras aplicar estos filtros (revisión por título, resumen y posteriormente texto completo), se seleccionaron **20 artículos científicos** que responden de manera directa a las preguntas de investigación y constituyen la base del presente estado del arte.

### B. Categorización de los trabajos

Los artículos se clasificaron de acuerdo con la pregunta principal que atiende cada uno, definiendo cuatro categorías:

- Arquitecturas y *frameworks* de mensajería multicanal (Q1).
- Técnicas y algoritmos de *machine learning* aplicados a notificaciones (Q2).
- Propuestas de sistemas de notificaciones inteligentes / orquestadores omnicanal (Q3).
- Estrategias de validación y evaluación de sistemas de notificaciones (Q4).

En la Tabla I se presenta la categorización general de los trabajos seleccionados.

TABLE I  
CATEGORIZACIÓN DE ARTÍCULOS SEGÚN PREGUNTAS DE INVESTIGACIÓN

| Categoría                                                            | Referencias               |
|----------------------------------------------------------------------|---------------------------|
| Arquitecturas y <i>frameworks</i> de mensajería multicanal           | [1] [2] [3] [4] [5]       |
| Técnicas y algoritmos de <i>machine learning</i> para notificaciones | [6] [7] [8] [9] [10] [11] |
| Propuestas de sistemas de notificaciones inteligentes                | [12] [13] [14] [15] [16]  |
| Estrategias de validación y evaluación                               | [17] [18] [19] [20]       |

### C. Arquitecturas y *frameworks* de mensajería multicanal (Q1)

En la categoría de *Arquitecturas y frameworks de mensajería multicanal*, los trabajos analizados se centran en cómo integrar diferentes canales de comunicación (correo electrónico, SMS, notificaciones *push*, mensajería instantánea) bajo un modelo arquitectónico unificado.

Diversos estudios [1]–[3] plantean arquitecturas basadas en *microservicios* y *API gateways* que abstraen la complejidad de los proveedores externos y exponen un punto de entrada homogéneo para las aplicaciones de negocio. Estas propuestas suelen incorporar patrones de diseño como *service mesh*, *circuit breaker* y colas de mensajes para garantizar **tolerancia**

a fallos, escalabilidad y monitoreo centralizado de las notificaciones.

Otros trabajos [4], [5] introducen *frameworks* conceptuales de mensajería omnicanal, en los que se define un modelo intermedio capaz de transformar un mismo evento de negocio en múltiples representaciones (plantillas de correo, SMS, *push*, etc.). Este tipo de enfoque es análogo al modelo IM3 de mensajería integrada y permite agregar o reemplazar canales sin modificar los sistemas origen. En general, los artículos de esta categoría aportan la base para el diseño del *Intelligent Online Notification Manager*, ya que demuestran la importancia de contar con una **capa de comunicación desacoplada** que centralice la lógica de envío, registro y seguimiento.

#### D. Técnicas y algoritmos de machine learning para notificaciones (Q2)

En la categoría de *Técnicas y algoritmos de machine learning para notificaciones*, los trabajos revisados exploran cómo mejorar la entrega y pertinencia de los mensajes utilizando modelos predictivos y de decisión.

Un grupo de artículos [6]–[8] aborda el problema como una tarea de **clasificación supervisada**. Se emplean algoritmos como árboles de decisión, *Random Forest*, *gradient boosting* y redes neuronales para predecir la probabilidad de que un usuario abra, haga clic o ignore una notificación, a partir de variables como tipo de mensaje, hora de envío, canal utilizado, dispositivo, historial de interacción y segmentación del cliente. Estos estudios reportan métricas de desempeño como *accuracy*, precisión, *recall* y F1-score superiores a los enfoques basados en reglas fijas, demostrando que los modelos supervisados capturan patrones de comportamiento subjetivos y contextuales.

Otros trabajos [9], [10] se enfocan en **aprendizaje por refuerzo** y algoritmos *multi-armed bandit*, tratando la planificación de notificaciones como un problema de decisión secuencial. En estos casos, el agente elige entre diferentes acciones (por ejemplo, enviar ahora, posponer, cambiar de canal) para maximizar una función de recompensa asociada a la interacción (apertura, conversión, ausencia de quejas). Estos estudios muestran que las políticas aprendidas se adaptan dinámicamente al comportamiento del usuario y pueden reducir la **fatiga por notificaciones**.

Finalmente, algunos autores [11] combinan ambas aproximaciones en modelos híbridos, donde la clasificación supervisada estima el canal o contenido óptimo, mientras que el aprendizaje por refuerzo ajusta el momento y la frecuencia de envío. Esta línea es especialmente relevante para la presente investigación, pues respalda el diseño de una **capa de inteligencia** que integra diferentes técnicas de *machine learning* para tomar decisiones más robustas sobre las notificaciones bancarias.

#### E. Propuestas de sistemas de notificaciones inteligentes (Q3)

En la categoría de *Propuestas de sistemas de notificaciones inteligentes / orquestadores omnicanal*, se encuentran trabajos

que describen soluciones completas, desde la capa de datos hasta la interfaz con el usuario.

Algunos artículos [12], [13] presentan plataformas de **orquestación de campañas** que unifican la gestión de correos, SMS y *push notifications* orientadas a marketing. Estos sistemas permiten definir reglas de segmentación y flujos de contacto, pero dependen en gran medida de reglas estáticas configuradas por el área de negocio, lo cual limita su capacidad de aprendizaje frente a cambios en el comportamiento del cliente.

Otros trabajos [14], [15] proponen gestores inteligentes de notificaciones contextuales, que integran modelos de *machine learning* para decidir no solo el canal, sino también el contenido y la secuencia de mensajes en función de eventos específicos (por ejemplo, transacciones, alertas de seguridad, recomendaciones personalizadas). En estos casos, la arquitectura se compone de módulos de ingesta de datos, motor analítico y componentes de entrega multicanal, muy similares a la estructura planteada en el presente proyecto.

Finalmente, algunos autores [16] abordan explícitamente el ámbito financiero y bancario, planteando sistemas de notificaciones orientados a mejorar la seguridad (alertas de fraude, movimientos inusuales) y la experiencia del cliente (recordatorios de pagos, ofertas personalizadas). Estos trabajos evidencian que la integración de *machine learning* en la mensajería bancaria permite **reducir el ruido de comunicaciones irrelevantes** y aumentar la efectividad de las notificaciones críticas, aspecto clave para justificar la implementación de un gestor inteligente en el contexto de la banca privada.

#### F. Estrategias de validación y evaluación (Q4)

En la categoría de *Estrategias de validación y evaluación de sistemas de notificaciones*, los trabajos analizados describen cómo se mide el impacto real de las soluciones propuestas tanto a nivel de modelo como de sistema completo.

Varios estudios [17], [18] se centran en la **validación cuantitativa de modelos de machine learning**, utilizando métricas estándar como precisión, *recall*, F1-score, AUC-ROC y matrices de confusión. En algunos casos se comparan múltiples algoritmos (por ejemplo, árboles de decisión frente a redes neuronales) para seleccionar el modelo que logra el mejor equilibrio entre desempeño y explicabilidad, aspecto importante cuando se manejan decisiones sensibles para el negocio.

Otros trabajos [19] complementan la evaluación técnica con **experimentos A/B** o pruebas controladas en producción, midiendo indicadores como tasa de apertura, clics, conversiones y reducción de bajas de suscripción antes y después de la introducción del sistema inteligente. Estos enfoques permiten cuantificar el valor agregado de la personalización y del ajuste dinámico del canal y del momento de envío.

Adicionalmente, algunos artículos [20] incorporan evaluaciones de **usabilidad y experiencia de usuario**, mediante encuestas, entrevistas y estudios de caso. Estas investigaciones ponen énfasis en dimensiones como percepción de intrusión, claridad de los mensajes, sensación de control del usuario y

confianza en la institución emisora (por ejemplo, un banco). La combinación de evaluación técnica y percepción del usuario resulta esencial para garantizar que los beneficios del sistema no se logren a costa de deteriorar la relación con el cliente.

### G. Síntesis del estado del arte

En conjunto, la revisión sistemática muestra que existe un avance significativo en:

- El diseño de arquitecturas y *frameworks* multicanal para la gestión de notificaciones.
- La aplicación de técnicas de *machine learning* (supervisado y por refuerzo) para optimizar canal, contenido y momento de envío.
- El desarrollo de plataformas inteligentes de notificaciones en contextos de servicios y, en menor medida, en banca.
- El uso de estrategias de validación robustas, que combinan métricas de modelo, indicadores de negocio y percepción de usuario.

No obstante, se identifica una brecha: son escasos los trabajos que integren de forma simultánea un **gestor unificado de notificaciones para banca privada**, una **capa de inteligencia híbrida** para la toma de decisiones (canal–momento–prioridad) y la **incorporación explícita de requisitos regulatorios y de seguridad** propios del sector financiero. Esta brecha es precisamente la que aborda la presente investigación mediante el diseño de un *Intelligent Online Notification Manager* basado en *machine learning* para la banca privada, el cual unifica los aportes identificados en las cuatro categorías analizadas.

## III. APOORTE: CONCEPTUALIZACIÓN DE LA PROPUESTA

El problema central que aborda este trabajo se sitúa en la **comunicación con los clientes de banca privada**. Diversos estudios sobre transformación digital en el sector financiero señalan que, a pesar de invertir en canales móviles, web y mensajería, muchos bancos siguen presentando comunicaciones **tardías, redundantes o incoherentes** entre canales [4], [5]. Estrategias multicanal mal integradas generan experiencias fragmentadas: un cliente puede recibir un correo tardío, un SMS duplicado y una notificación *push* que no refleja su situación actual [1]. Reportes de la industria muestran, además, que cerca del 98 % de los clientes esperan experiencias coherentes en todos los puntos de contacto [2].

Este trabajo propone como aporte conceptual un **Gestor Inteligente de Notificaciones Online** para banca privada, diseñado como una plataforma que integra dos dimensiones inseparables:

- 1) **Comunicación bancaria centrada en el cliente:** garantizar que los mensajes lleguen al cliente de forma oportuna (momento adecuado) y consistente (mismo criterio de negocio en todos los canales), considerando su contexto y preferencias [1], [5].
- 2) **Arquitectura y *machine learning*:** utilizar una arquitectura de microservicios y modelos de aprendizaje automático para tomar decisiones sobre qué mensaje

enviar, por qué canal, en qué momento y con qué prioridad, de manera automatizada y escalable [4], [6].

En lugar de que cada sistema interno (banca móvil, banca web, CRM, *core* bancario) gestione sus propias reglas y conexiones a proveedores de mensajería, el modelo introduce un **gestor central** que:

- recibe eventos de negocio mediante una API unificada de notificaciones;
- consulta el historial de interacciones y preferencias de comunicación del cliente;
- aplica modelos de *machine learning* para seleccionar canal, momento y prioridad;
- ejecuta el envío a través de adaptadores de canal estandarizados; y
- registra la trazabilidad completa para evaluar oportunidad, consistencia y cumplimiento regulatorio.

La Fig. 1 resume este aporte conceptual. El modelo se organiza en tres capas principales: **capa de datos**, **capa de inteligencia** y **capa de comunicación**. La propuesta se inspira en marcos de mensajería multicanal como IM3 [3], [7], en estrategias de comunicación centradas en el cliente [5] y en trabajos sobre integración tecnológica en banca [4].




Fig. 1. Modelo conceptual del Gestor Inteligente de Notificaciones Online para lograr comunicación oportuna y consistente en banca privada.

1) **Capa de datos:** La capa de datos consolida información dispersa sobre comunicación y operación bancaria: eventos de negocio, historial de notificaciones, respuestas del cliente (aperturas, clics, quejas, bajas) y atributos del cliente (segmento, preferencias de canal, ventanas horarias preferidas). En línea con [4], su objetivo es eliminar silos de información y ofrecer una vista unificada que permita diagnosticar dónde la comunicación es tardía, redundante o incoherente.

2) **Capa de inteligencia:** La capa de inteligencia transforma datos en decisiones. Se compone de modelos de *machine learning* supervisado que predicen el canal y la prioridad más efectivos, y de un agente de aprendizaje por refuerzo que decide el momento y la frecuencia del envío [8], [9]. Así, la plataforma aprende de la respuesta real de los clientes y ajusta la comunicación para que sea más oportuna, relevante y alineada con su contexto.

3) **Capa de comunicación:** La capa de comunicación orquesta la ejecución coherente de las decisiones en todos

los canales: correo, SMS, notificaciones *push*, mensajería instantánea, entre otros. Utiliza adaptadores basados en microservicios y *service mesh* para encapsular la complejidad de cada proveedor [10], y se apoya en marcos de notificación en dispositivos inteligentes para gestionar el contexto de entrega [11]. Además, incorpora controles y trazabilidad alineados con la Resolución SBS N.504-2021 y la norma ISO/IEC 27001 [12], [13], garantizando que la mejora en la comunicación no comprometa la seguridad de la información.

En síntesis, el aporte conceptual integra **objetivos de comunicación** (oportunidad y consistencia de los mensajes) con **mecanismos tecnológicos** (arquitectura y *machine learning*), estableciendo una base clara para el diseño detallado del sistema propuesto.

#### IV. APORTE: EXPLICACIÓN DE DETALLE DE LA PROPUESTA

Mientras que la sección anterior describió el modelo conceptual, en esta sección se explican en detalle los componentes del *Gestor Inteligente de Notificaciones Online* y cómo trabajan en conjunto para mejorar la comunicación bancaria (oportunidad y consistencia) mediante una arquitectura escalable y modelos de *machine learning*.

Para describir un sistema complejo como el Gestor Inteligente de Notificaciones, la arquitectura de software se descompuso en diferentes **vistas**. Las vistas de arquitectura son representaciones que describen el sistema desde la perspectiva de distintos interesados, como desarrolladores, administradores de sistemas y analistas de negocio. Cada vista se enfocó en aspectos específicos, por ejemplo:

- la **vista lógica**, que describe qué hace el sistema (módulos, componentes y sus responsabilidades);
- la **vista de procesos**, que explica cómo se ejecutan los flujos, la concurrencia y el uso de colas y servicios;
- la **vista física**, que muestra cómo se desplegaron los componentes en la infraestructura (servicios de nube, balanceadores, caché, etc.).

En el contexto de este proyecto, la **Arquitectura Técnica Base**, presentada en la Fig. 2, constituyó la vista principal que integró los componentes clave de la solución. Esta vista combinó elementos de:

- una **vista lógica**, al mostrar módulos como el Módulo de Validación, el Módulo de Decisión de Prioridad (ML) y el Servicio de Orquestación;
- una **vista de procesos**, al representar el flujo de datos, las colas de prioridad y los servicios de despacho hacia los canales de comunicación;
- y una **vista física**, al detallar elementos de infraestructura en nube como el balanceador de carga, la caché y los servicios de mensajería externos.

Su propósito fue ofrecer una visión integral del flujo de datos, desde que la API de notificaciones recibió la solicitud hasta que el mensaje fue despachado al proveedor de mensajería correspondiente, integrando en una sola vista los aspectos de comunicación, arquitectura y *machine learning* que sustentaron la propuesta.




Fig. 2. Arquitectura técnica base del Gestor Inteligente de Notificaciones Online. Nota. Imagen de elaboración propia.

#### A. Capa de datos e ingesta de información

La capa de datos es responsable de capturar y organizar toda la información necesaria para tomar decisiones de comunicación basadas en evidencia. Siguiendo [4], esta capa se diseña para integrar fuentes heterogéneas y habilitar un análisis consistente de la experiencia del cliente.

Los datos clave son:

- **Eventos de negocio:** indican qué está ocurriendo con el cliente (transacciones sospechosas, vencimientos de pagos, aprobaciones, cambios de condiciones). Cada evento incluye tipo, criticidad, canal sugerido y metadatos relevantes.
- **Historial de notificación:** registra qué se comunicó, cuándo, por qué canal y con qué resultado (entregado, abierto, ignorado, queja, baja). Esto permite medir si la comunicación fue oportuna, redundante o incoherente.
- **Perfil y preferencias del cliente:** almacena información de segmento, canales preferidos, ventanas horarias recomendadas, restricciones legales y sensibilidad a la frecuencia de mensajes [1], [5].

Estos datos se almacenan en un repositorio preparado para análisis (por ejemplo, *data warehouse* o *data lake*), y se exponen a la capa de inteligencia mediante vistas o servicios especializados. La calidad, consistencia y actualización de estos datos son esenciales para que las decisiones de *machine learning* mejoren efectivamente la comunicación.

### B. Capa de inteligencia: modelos supervisados para canal y prioridad

El primer bloque de la capa de inteligencia agrupa los modelos de *machine learning* supervisado encargados de decidir **qué canal** y con **qué prioridad** se debe comunicar cada evento. Estos modelos siguen la línea de trabajos que abordan las notificaciones como un problema de clasificación y predicción de respuesta [4], [8].

El proceso general es:

- 1) A partir del historial de notificaciones se construyen conjuntos de entrenamiento donde cada instancia representa un intento de comunicación con su contexto (tipo de evento, hora, canal utilizado, dispositivo, historial reciente, segmento del cliente).
- 2) La etiqueta indica el resultado de comunicación de interés: apertura, clic, queja, silencio, baja u otra acción relevante.
- 3) Se entrenan modelos como árboles de decisión y *Random Forest*, que permiten capturar interacciones no lineales entre variables y ofrecen explicabilidad razonable frente a modelos opacos [4].
- 4) En tiempo de ejecución, el modelo recibe un nuevo evento y devuelve un vector de probabilidades para cada canal (correo, SMS, notificaciones *push*, mensajería instantánea), así como una recomendación de prioridad (crítica, informativa, comercial).

De esta forma, el gestor puede reservar canales más intrusivos para comunicaciones críticas y asignar canales menos invasivos a mensajes informativos o promocionales, alineando la estrategia con las mejores prácticas de comunicación multicanal [1], [5].

*C. Capa de inteligencia: aprendizaje por refuerzo para oportunidad y frecuencia*

El segundo bloque de la capa de inteligencia utiliza aprendizaje por refuerzo (RL) para decidir **cuándo** y **con qué frecuencia** enviar notificaciones, variables directamente asociadas a la oportunidad e intrusividad de la comunicación. Este enfoque sigue trabajos que modelan la planificación de notificaciones como un proceso de decisión secuencial [8], [9].

En este contexto:

- El **estado** incluye la información temporal (hora del día, día de la semana), la carga reciente de notificaciones enviadas al cliente y su respuesta agregada (tasa de aperturas, quejas, silencios).
- Las **acciones** comprenden enviar la notificación de inmediato, posponerla a una franja posterior, agruparla con otras comunicaciones o descartarla en caso de baja relevancia.
- La **recompensa** combina aspectos positivos (aperturas, clics, acciones deseadas) y negativos (quejas, bajas, alta proporción de notificaciones ignoradas), siguiendo la lógica de trabajos como [8], [9].

El agente aprende una política que maximiza la recompensa acumulada, logrando un equilibrio entre informar de manera




Fig. 3. Arquitectura detallada del Gestor Inteligente de Notificaciones Online propuesto.

oportuna y evitar la saturación del cliente. Así, por ejemplo, puede aprender que ciertos segmentos responden mejor a notificaciones en horarios específicos y que algunos tipos de mensajes no deben repetirse más allá de un umbral de frecuencia.

#### D. Servicio de orquestación de notificaciones

El servicio de orquestación representa el **punto de unión entre comunicación, arquitectura y *machine learning***. Su función es transformar eventos de negocio dispersos en decisiones de comunicación coordinadas.

En línea con [6], [10], sus responsabilidades incluyen:

- Recibir eventos desde el API Gateway y registrarlos en la capa de datos.
- Consultar el historial y el perfil del cliente para construir el contexto comunicacional.
- Invocar a los modelos supervisados para obtener canal y prioridad recomendados.
- Invocar al agente RL para decidir si enviar ahora o reprogramar el envío.
- Construir el mensaje final (plantilla, personalización, idioma) y emitir un comando estandarizado al adaptador de canal.
- Registrar las respuestas de los adaptadores (entregado, fallido, reintentado) y actualizar la capa de datos.

Gracias a esta orquestación centralizada, el banco puede asegurar que una misma regla de negocio produce mensajes coherentes en todos los canales, reduciendo contradicciones y duplicidades.

La Fig. 3 presenta la arquitectura detallada propuesta. Se observa el flujo de información desde los sistemas de negocio hacia la capa de datos, la capa de inteligencia y la capa de comunicación. Esta arquitectura combina principios de integración tecnológica en banca [4], estrategias de comunicación multicanal [1], [5] y marcos de mensajería financiera basados en microservicios [6], [10].

### E. Adaptadores de canal y capa de comunicación

Los adaptadores de canal implementan la interacción con proveedores externos de mensajería (Firebase/FCM, APNs, proveedores SMS, servidores SMTP, APIs de mensajería



instantánea). Siguen el modelo de mensajería multicanal como IM3 [3], [7] y los patrones de microservicios recomendados en [10].

Cada adaptador:

- recibe un comando de envío estandarizado desde el servicio de orquestación;
- lo transforma al formato requerido por el proveedor (payload, cabeceras, parámetros de autenticación);
- ejecuta la llamada a la API externa y gestiona reintentos básicos; y
- reporta el estado de la entrega al sistema (aceptado, entregado, fallido, rechazado).

Este diseño permite agregar o sustituir canales sin modificar la lógica central, manteniendo la consistencia de los mensajes aunque la infraestructura tecnológica evolucione [1], [5].

#### *F. Monitoreo, métricas y retroalimentación*

Este componente mide el impacto real de la plataforma sobre la comunicación con el cliente. Inspirado en [4], [8], utiliza métricas tanto técnicas como de negocio:

- precisión, *recall* y F1-score del modelo de clasificación para selección de canal;
- recompensa promedio y estabilidad de la política del agente RL;
- latencia de extremo a extremo (capacidad de entregar mensajes oportunos);
- tasas de entrega, apertura y acción por canal y tipo de notificación;
- volumen y tipo de quejas o bajas asociadas a la comunicación.

Los resultados se utilizan para reentrenar modelos, ajustar umbrales y revisar reglas de negocio, siguiendo una lógica de mejora continua alineada con las expectativas de los clientes [2].

#### *G. Seguridad, cumplimiento y trazabilidad*

Finalmente, el componente de seguridad y cumplimiento garantiza que la arquitectura propuesta respete las exigencias normativas del sistema financiero peruano y los estándares internacionales de seguridad de la información. La solución se alinea con la Resolución SBS N.504–2021 y la norma ISO/IEC 27001 [12], [13].

Entre los mecanismos clave están:

- autenticación y autorización robusta en el API Gateway (OAuth 2.0, JWT);
- cifrado de datos en tránsito y en reposo;
- registros de auditoría para cada notificación, que permiten reconstruir qué se comunicó, cuándo y por qué canal;
- políticas de retención y anonimación de datos acordes con la regulación.

De este modo, la mejora en la comunicación (más oportuna y consistente) se logra sin comprometer la confidencialidad, integridad y disponibilidad de la información, sino reforzándolas mediante una arquitectura segura y auditable.

En conjunto, la explicación de detalle muestra cómo el problema de comunicación en banca privada se afronta simultáneamente desde la **estrategia comunicacional** (decisiones de canal, momento, prioridad) y desde la **ingeniería de sistemas** (arquitectura y *machine learning*), materializando el modelo conceptual propuesto.

### V. PROPUESTA DE VALIDACIÓN

Para corroborar la validez del *Gestor Inteligente de Notificaciones Online* se propone un proceso de validación mixto (cuantitativo y cualitativo) orientado a responder si la solución:

- 1) mejora la **oportunidad** y **consistencia** de la comunicación con los clientes de banca privada;
- 2) mantiene un desempeño técnico aceptable (latencia, disponibilidad, errores) de la **arquitectura** propuesta; y
- 3) alcanza niveles adecuados de calidad en los **modelos de machine learning** (selección de canal, prioridad, momento de envío).

El diseño de la validación se inspira en estudios previos de transformación digital en banca [4], estrategias de comunicación multicanal en servicios financieros [1], [5] y evaluaciones de sistemas inteligentes de notificación [8], [9].

#### *A. Caso de estudio, muestra y sujetos de estudio*

La validación se planteará como un **estudio de caso** en una unidad específica de banca privada (por ejemplo, clientes de un segmento de productos o de una región determinada). El objetivo es observar el comportamiento del sistema en un entorno realista, pero controlado.

Se consideran tres tipos de sujetos de estudio:

- **Clientes finales:** usuarios que reciben notificaciones relacionadas con operaciones, alertas y recordatorios. Se buscará conformar una muestra de al menos  $N_c$  clientes (por ejemplo, del orden de 100–300), estratificada según canal preferido y tipo de producto, para medir oportunamente tasas de entrega, apertura y percepción de coherencia comunicacional [2], [5].
- **Personal interno:** analistas de canales digitales, riesgos y atención al cliente, que usarán tableros y reportes del sistema. Se espera involucrar al menos  $N_i$  colaboradores para evaluar la facilidad de interpretación de la información, la trazabilidad y el soporte a la toma de decisiones.
- **Datos históricos:** registros de notificación previos (antes de la implementación del gestor) que servirán como línea base para comparación de métricas cuantitativas [4].

El estudio se desarrollará en dos fases:

- 1) **Fase baseline:** recopilación de métricas de comunicación bajo el esquema actual (sin gestor inteligente).
- 2) **Fase piloto:** despliegue controlado del gestor en el mismo segmento de clientes y comparación de resultados, complementada con encuestas de percepción y usabilidad.

## B. Métricas cuantitativas

Siguiendo las recomendaciones de la literatura sobre integración tecnológica y evaluación de sistemas inteligentes de notificación [4], [8], [9], se proponen métricas agrupadas en tres dimensiones: comunicación, arquitectura y *machine learning*. La Tabla II resume las principales métricas y sus resultados esperados.

TABLE II  
MÉTRICAS PROPUESTAS PARA LA VALIDACIÓN DEL SISTEMA

| Métrica                                   | Descripción                                                                                                          | Objetivo                  |
|-------------------------------------------|----------------------------------------------------------------------------------------------------------------------|---------------------------|
| Latencia de entrega                       | Tiempo promedio entre la generación del evento y la recepción de la notificación en el dispositivo del cliente.      | < 5 s                     |
| Tasa de entrega                           | Porcentaje de notificaciones aceptadas por el canal (sin rebotes ni errores fatales).                                | ≥ 95%                     |
| Tasa de apertura por canal                | Porcentaje de notificaciones abiertas respecto al total entregado por canal (correo, SMS, <i>push</i> , mensajería). | Mejora vs. baseline       |
| Channel Selection Accuracy                | Porcentaje de casos en los que el canal sugerido por el modelo coincide con el canal de mayor respuesta observada.   | ≥ 80%                     |
| Recompensa promedio RL                    | Valor promedio de la recompensa del agente de aprendizaje por refuerzo (combina aperturas, clics, quejas y bajas).   | Incremento vs. baseline   |
| Incidencias de comunicación inconsistente | Número de casos de mensajes duplicados o contradictorios detectados en una ventana de tiempo.                        | Disminución significativa |
| Disponibilidad del servicio               | Porcentaje de tiempo en que el API de notificaciones y los componentes centrales están operativos.                   | ≥ 99%                     |

Estas métricas permitirán evaluar si la arquitectura propuesta mantiene niveles aceptables de rendimiento y disponibilidad [10], a la vez que se verifica el aporte de los modelos de *machine learning* a la mejora de la comunicación (oportunidad, relevancia y reducción de inconsistencias) [2], [5].

## C. Evaluación cualitativa y usabilidad

Además de las métricas cuantitativas, se aplicará una encuesta de percepción y usabilidad, tanto a clientes seleccionados como a personal interno que interactúa con los tableros del sistema. Siguiendo trabajos que enfatizan la importancia de la experiencia de usuario en sistemas de notificación [2], [11], se propone una escala tipo Likert de 5 puntos, donde 1 representa una valoración muy negativa y 5 una valoración muy positiva.

La Tabla III muestra ejemplos de preguntas sugeridas orientadas específicamente al problema de comunicación bancaria y al uso del sistema propuesto.

Para el personal interno, se adaptarán preguntas similares, enfocadas en:

- facilidad de interpretación de los tableros de monitoreo;
- utilidad de los indicadores para gestionar campañas y alertas;
- percepción de mejora en la coherencia de la comunicación entre áreas.

TABLE III

EJEMPLOS DE ÍTEMS DE ENCUESTA PARA EVALUAR COMUNICACIÓN Y USABILIDAD

| # | Pregunta (escala 1–5)                                                                                                                                                                                    |
|---|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1 | En una escala del 1 al 5, indique qué tan oportuna considera la recepción de las notificaciones del banco (1 = Muy inoportuna, 5 = Muy oportuna).                                                        |
| 2 | En una escala del 1 al 5, indique qué tan consistente percibe la información recibida a través de distintos canales (correo, SMS, <i>push</i> , mensajería) (1 = Nada consistente, 5 = Muy consistente). |
| 3 | En una escala del 1 al 5, indique qué tan claro le resulta el contenido de las notificaciones generadas por el sistema (1 = Muy confuso, 5 = Muy claro).                                                 |
| 4 | En una escala del 1 al 5, indique qué tan apropiado considera el canal utilizado para las notificaciones que ha recibido (1 = Muy inapropiado, 5 = Muy apropiado).                                       |
| 5 | En una escala del 1 al 5, indique en qué medida las notificaciones le ayudan a gestionar mejor sus productos financieros (1 = Nada, 5 = Mucho).                                                          |

## D. Procedimiento de validación

El procedimiento general de validación seguirá los siguientes pasos:

- 1) **Definición de segmento y periodo de estudio:** selección de un segmento de clientes y de un periodo de observación (por ejemplo, 4–8 semanas) para la comparación entre baseline y piloto.
- 2) **Recopilación de datos baseline:** medición de las métricas de la Tabla II bajo el esquema actual de comunicación, sin el gestor inteligente.
- 3) **Despliegue controlado del sistema:** activación del Gestor Inteligente de Notificaciones Online para el mismo segmento, manteniendo condiciones similares de volumen y tipo de eventos.
- 4) **Medición de métricas:** cálculo de las métricas cuantitativas durante el piloto y comparación con el baseline, analizando mejoras en oportunidad, consistencia y desempeño de los modelos de *machine learning* [8], [9].
- 5) **Aplicación de encuestas:** administración de los cuestionarios de la Tabla III a una muestra de clientes y personal interno, recopilando evidencia de percepción de mejora comunicacional y usabilidad [2], [11].
- 6) **Análisis e interpretación:** integración de resultados cuantitativos y cualitativos para determinar si la propuesta cumple con los objetivos de comunicación (mensajes más oportunos y consistentes), mantiene un rendimiento aceptable de la arquitectura y alcanza niveles satisfactorios en los modelos de *machine learning*.

Este esquema de validación busca demostrar, de manera empírica, que la combinación de una arquitectura de microservicios con modelos de *machine learning* no solo es viable desde el punto de vista técnico, sino que también contribuye a resolver el problema de comunicación oportuna y consistente en la banca privada.

## VI. CONCLUSIONES

El estudio se centró en el problema de la comunicación digital en la banca privada, caracterizada por mensajes tardíos,



redundantes o incoherentes entre canales, y propuso el diseño de un *Gestor Inteligente de Notificaciones Online* sustentado en una arquitectura de microservicios y modelos de *machine learning*. A partir del análisis del estado del arte, de la conceptualización del modelo, del diseño detallado de la arquitectura y de la propuesta de validación, se obtuvieron las siguientes conclusiones.

En primer lugar, se concluyó que la integración de los objetivos de comunicación (oportunidad, consistencia y relevancia de los mensajes) con una arquitectura unificada de notificaciones permitió plantear una solución más coherente que el esquema tradicional de canales aislados. El modelo de tres capas (datos, inteligencia y comunicación) conceptualizó de manera clara cómo los eventos de negocio, el historial de interacciones y las preferencias del cliente podían convertirse en decisiones de comunicación más alineadas con las necesidades del usuario bancario.

En segundo lugar, se concluyó que la arquitectura basada en microservicios, API de notificaciones, servicio de orquestación y adaptadores de canal resultó adecuada para soportar la escalabilidad, la extensibilidad y el cumplimiento regulatorio requeridos en el entorno financiero. La separación entre capa de datos, capa de inteligencia y capa de comunicación facilitó la integración con sistemas existentes, la incorporación de nuevos canales y la aplicación de controles de seguridad y trazabilidad alineados con las normas vigentes.

En tercer lugar, se concluyó que la combinación de modelos supervisados para la selección de canal y prioridad con un agente de aprendizaje por refuerzo para la decisión del momento y la frecuencia de envío constituyó un enfoque viable para optimizar la comunicación con los clientes. Este esquema permitió plantear métricas específicas de desempeño (precisión de selección de canal, recompensa promedio del agente, tasas de apertura y reducción de inconsistencias) que conectaron directamente el comportamiento de los modelos de *machine learning* con los objetivos de comunicación del banco.

Finalmente, se concluyó que la propuesta de validación, basada en un estudio de caso con comparación *baseline*–piloto, métricas cuantitativas y encuestas de usabilidad, constituyó un marco adecuado para corroborar empíricamente la validez de la solución. Este esquema permitió vincular indicadores técnicos de arquitectura (latencia, disponibilidad, errores) y de modelos de *machine learning* con la percepción de oportunidad, consistencia y utilidad de las notificaciones por parte de los clientes y del personal interno de la banca privada.

## REFERENCES

- [1] A. Alzahrani and B. Alhaqabani, "Digital communication strategies in financial technology: Improving multi-channel integration," *International Journal of Advanced Computer Science and Applications*, vol. 11, no. 5, pp. 128–135, 2020.
- [2] Twilio Inc., "The state of customer engagement report 2023," 2023, available at: <https://www.twilio.com/state-of-customer-engagement>.
- [3] T.-P. Liang and E. Turban, "Introduction to the special issue: Social commerce: A research framework for social commerce," *International Journal of Electronic Commerce*, vol. 16, no. 2, pp. 5–14, 2011.
- [4] M. Rahimi and M. Ghobakhloo, "Digital transformation in banking: The role of technology integration," *Journal of Financial Innovation*, vol. 8, no. 3, pp. 112–120, 2021.
- [5] D. Torres and L. Muñoz, "Multi-channel customer communication strategies in financial services," *Latin American Journal of Management and Innovation*, vol. 5, no. 1, pp. 45–53, 2020.
- [6] O. Salami and E. Mnkandla, "A design for a machine-learning-enabled multi-channel messaging framework for financial service institutions," in *2022 International Conference on Artificial Intelligence, Big Data, Computing and Data Communication Systems (icABCD)*. IEEE, 2022. [Online]. Available: <https://doi.org/10.1109/icABCD54961.2022.9856210>
- [7] S. Liu, "An integrated multi-channel messaging model supporting for business collaboration [figure]," IEEE Xplore, 2011, available at: <https://ieeexplore.ieee.org/document/6112142>.
- [8] E. Yancey and B. Settles, "Recovering difference softmax algorithm for optimizing user retention in intelligent notification systems," in *Proceedings of the 2020 Conference on Intelligent Systems*. ACM, 2020.
- [9] P. Prabhakar, Y. Yuan, G. Yang, W. Sun, and A. Muralidharan, "Multi-objective optimization of notifications using offline reinforcement learning," arXiv preprint arXiv:2207.03029, 2022. [Online]. Available: <https://arxiv.org/abs/2207.03029>
- [10] A. Nicolas-Plata, J. L. Gonzalez-Compean, and V. J. Sosa-Sosa, "A service mesh approach to integrate processing patterns into microservices applications," *Cluster Computing*, vol. 27, pp. 7417–7438, 2024. [Online]. Available: <https://doi.org/10.1007/s10586-024-04342-5>
- [11] G. López and L. A. Guerrero, "A conceptual framework for smart device-based notifications," *Journal of Ambient Intelligence and Humanized Computing*, vol. 13, no. 11, pp. 5433–5445, 2020, online first: Feb 2020; final issue pagination in 2022. [Online]. Available: <https://doi.org/10.1007/s12652-020-01801-w>
- [12] Superintendencia de Banca, Seguros y AFP (SBS), "Resolución sbs n.º 504-2021: Reglamento para la gestión de la seguridad de la información y la ciberseguridad," 2021, reglamento oficial de seguridad de la información para entidades del sistema financiero en el Perú. [Online]. Available: [https://www.sbs.gob.pe/app/pp/int\\_cn/paginas/busqueda/Download.aspx?url=p8ehJETNq5hYZsadCTQIDA1Pw7aAvNcREl6DVQhESNiouiM3fzeprEqSY0+Ubw+IMYa9V8Zay%2FmgvD1uvX66Ar+LIbOKeBV02kcyJ2IZ6v4H2QIXJdRcngUYbKeMk6iiTj0PbAeIInvl2RoVoDZI9yob5jtf2FKMISH4rags7zMKSVIHepUDpVyvKLUC7izoAtxSVrjxFwYv9y09Rg%3D%3D](https://www.sbs.gob.pe/app/pp/int_cn/paginas/busqueda/Download.aspx?url=p8ehJETNq5hYZsadCTQIDA1Pw7aAvNcREl6DVQhESNiouiM3fzeprEqSY0+Ubw+IMYa9V8Zay%2FmgvD1uvX66Ar+LIbOKeBV02kcyJ2IZ6v4H2QIXJdRcngUYbKeMk6iiTj0PbAeIInvl2RoVoDZI9yob5jtf2FKMISH4rags7zMKSVIHepUDpVyvKLUC7izoAtxSVrjxFwYv9y09Rg%3D%3D)
- [13] International Organization for Standardization, *ISO/IEC 27001: Information Security Management Systems — Requirements*, ISO, Geneva, Switzerland Std., 2022.